Narración de cultivos.

Jorge D. Amezola A01793579, José S. Rueda A01794118, Diego A. del Valle A01747310
Tecnológico de Monterrey
Monterrey, México

La utilización de tecnologías emergentes como la visión computacional y la implementación de modelos avanzados de reconocimiento son ambas herramientas que se utilizan hoy en dia para apoyar el crecimiento de cultivos. En el presente artículo se explora un desarrollo propuesto basado en transformadores visuales, o *ViT* por sus siglas en inglés, como perceptores y *LLMs* como interpretadores de la información alimentada. Las imágenes utilizadas se obtienen de la base de datos *Panoptic Agricultural Satellite Time Series*, o PASTIS. Se exploran los datos utilizados, algoritmos propuestos y utilizados, y análisis de los resultados.

Adicionalmente, el reporte busca profundizar en las propuestas, explicar los beneficios de estas, y comprender como podrían llevarse a una solución utilizable. En este caso, los algoritmos previstos son los siguientes: *Contrastive Language-Image Pre-Training*, o *CLIP*; *BeMyEyes*, y combinaciones de estos con transformadores visuales tempos espaciales, o *TSViT* por sus siglas en ingles.

I. Introducción

El desarrollo de herramientas tecnológicas específicas para usos en la agricultura es un concepto que lleva siendo implementado desde tiempos lejanos. Desde la invención de la rueda y la domesticación de animales hasta la construcción de vehículos y optimización de cultivos, la innovación ha ayudado a la mejora continua de la agricultura.

En el caso de la optimización de cultivos, las innovaciones han dado un gran salto en cuanto a planificación y monitoreo gracias a las tecnologías que se han desarrollado últimamente. La computación ofrece un apoyo masivo en estos rubros, especialmente con la introducción de la inteligencia artificial, o en este caso de la visión computacional, en donde existen implementaciones de herramientas tales como control de plagas, salud de ganado en amplias planicies, y en el caso a explicar a continuación narración de cultivos basado en imágenes satelitales.

Este artículo busca profundizar en implementaciones de diferentes ideas que en conjunto apoyarán con la automatización de la comprensión de lo que está siendo cultivado en un dado momento. Por medio de investigación de otros desarrollos similares se busca llegar a una nueva solución que integre la visualización del cultivo con una comprensión y segmentación automatizada de lo que aparece en pantalla en un dado momento.

El proyecto como se menciona se sitúa en el contexto de la agricultura de precisión y el análisis de imágenes satelitales, donde grandes volúmenes de datos visuales requieren ser interpretados de forma comprensible para la toma de decisiones. Se considera que el sistema está orientado a agricultores, ingenieros agrónomos, analistas de datos, e instituciones que puedan aprovechar el estudio para promover o desarrollar herramientas similares. La solución propuesta está basada en un perceptor intérprete, inspirado en *BeMyEyes [1]*, y un enfoque basado en modelos de alineación visión-lenguaje como *CLIP[2]*.

II. Comprensión de datos

Los datos encontrados en la base de datos PASTIS consisten en imágenes satelitales de zonas agrícolas de Francia, que representan distintos tipos de cultivo, uso de suelo, y características visuales del terreno. Puede haber imágenes multiespectrales o RGB, dependiendo de la fuente.

Por medio de un análisis exploratorio, se encontró que dentro de la base de datos existen 20 cultivos descritos en inglés: *Background, Meadow, Soft, Corn, Winter barley, Winter rapeseed, Spring barley, Sunflower, Grapevine, Beet, Winter triticale, Winter durum wheat, Fruits/veg/flowers, Potatoes, Leguminous fodder, Soybeans, Orchard, Mixed cereal, Sorghum,* y *Void/Mixed*. También se utilizaron 10 bandas espectrales y 3 canales de polarización provenientes de los satélites que tomaron las fotos llamadas *Sentinel*. Las imágenes son cargadas por parcelas. Al momento de ser cargadas, se cargan como un diccionario con la siguiente estructura:

- s2: Imágenes Sentinel-2 (T, 10, 128, 128) - T timestamps, 10 bandas
- s1a: Imágenes Sentinel-1 Ascending (T, 3, 128, 128)
- s1d: Imágenes Sentinel-1 Descending (T, 3, 128, 128)
- annotations: Máscaras de segmentación (3, 128, 128)

Esto permite validar la dimensionalidad de los datos, los tipos numéricos utilizados, y la coherencia entre sensores, asegurando así que el *dataset* cumple con la estructura esperada para tareas de clasificación o segmentación.

Se realizó un análisis de completitud de datos sobre una muestra representativa para verificar la disponibilidad de datos en cada modalidad. Se evaluó la presencia o ausencia de cada tipo de dato, existencia de valores nulos, y número de *timestamps* por sensor. Este análisis es crucial debido a que inconsistencias en el número de observaciones temporales pueden afectar el desempeño de modelos que dependen de secuencias completas. En la imagen 1 se puede apreciar de mejor manera los resultados.

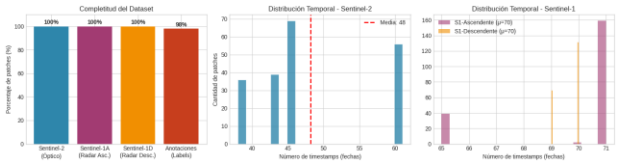

Imagen 1: Analisis de competitud

De igual manera, tambien se analizaron las estadística

descriptivas de las bandas espectrales de los satelites,utilizando archivos de normalizacoión precomputados. En el caso de Semntinel-2, las bandas representan diferentes regiones del espectro electromagnético visible, infrarrojo cercano, y SWIR. En el caso del Sentinel-1 se analizó la media y variabilidad por canal de polarización. Ambos analisis son fundamentales para validar la correcta normalización de datos, tetectar posibles saturaciones e inconsistencias, y diseñar estrategias de estandarización adecuadas para el entrenamiento del modelo. En la imagen 2 se muestran los resultados.

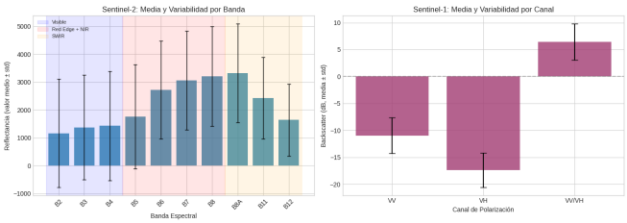

Imagen 2: Estadísticas de las bandas espectales.

Por último, se realizó un análisis de las clases de cultivos al realizar un conteo de pixeles por clase utilizando mascaras de segmentación. El propósito fue el de estimar la distribución real de cultivos en el dataset para cuantificar el grado de desbalance entre clases. El análisis mostró que efectivamente algunas clases dominan una mayor proporción total de pixeles, mientras que otras están subrepresentadas. Este desbalance puede provocar que el modelo tienda a favorecer a clases mayoritarias. Se puede ver el desbalance en la imagen 3.

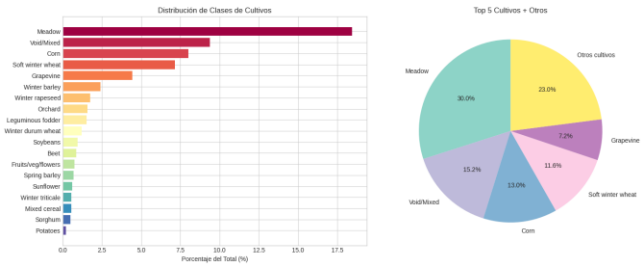

Imagen 3. Distribución de clases de cultivos.

Visto lo anterior, se considera que el análisis confirma que el *dataset* presenta una estructura organizada y consistente, con datos multitemporales bien definidos y estadísticas coherentes por banda espectral. Sin embargo, se puede ver claramente que hay un desbalanceo en las clases, lo cual puede ser perjudicial al momento de obtener resultados. Se puede explicar fácilmente este desbalanceo basándose en la rareza de cada cultivo en las parcelas.

III. Análisis e ingeniería de características

El proceso de análisis e ingeniería de características tiene como objetivo transformar la estructura original del *dataset* satelital y comprimirlo para simplificar su entendimiento al momento de ser entrenado. Dado a que el *dataset* contiene series temporales multiespectrales de alta dimensionalidad, se implementó una estrategia sistémica que redujera complejidad sin sacrificar información relevante para la clasificación de clases.

Cada parcela está representada por una serie temporal de imágenes con entre 38y 61 adquisiciones a lo largo del año. Dada esta estructura multitemporal, se introduce una dimensionalidad elevada que dificulta el uso de modelos tradicionales e incrementa el costo computacional. Para resolver esto, se realizó una reducción temporal mediante el cálculo de estadísticas descriptivas por banda espectral. Específicamente, se utilizó la media, desviación estándar, y el valor máximo a lo largo del eje temporal. La media se consideró debido a que permite capturar el comportamiento promedio del cultivo durante el año, la desviación se consideró para modelar la variabilidad fenológica, y el valor máximo permite identificar picos de vigor en las etapas clave de crecimiento de los cultivos. Esta estrategia permite condensar información en un conjunto fijo de características, y a su vez manteniendo señales relevantes del ciclo agrícola sin necesidad de procesar secuencias completas.

Además de utilizar directamente las bandas espectrales, se incorporó el índice NDVI, o *Normalized Difference Vegetation Index*, calculado a partir de la banda infrarroja cercana y la banda roja. Este índice es muy útil en la agricultura para medir vigor y densidad de vegetación, y se incluyó debido a que se considera que pese a que un modelo puede incorporar implícitamente las mismas relaciones al mostrarlas explícitamente reduce la carga de aprendizaje u facilita la separabilidad entre glases. De esta forma, el modelo no depende únicamente de combinaciones arbitrarias de reflectancias sino que también dispone de una señal significativa dada desde el entrenamiento.

Una vez construidas las variables agregadas, se observó dentro de las características se presentaban escalas heterogéneas y distribuciones potencialmente sesgadas. Se considera esperable dentro de los datos satelitales, donde diferentes bandas operan en rangos distintos. Por esta misma razón se aplicó una estandarización mediante la librería de sklearn y el método de *StandardScaler* para asegurar que todas las variables tuvieran media cero y varianza unitaria.

Después de la normalización, se procedió a eliminar características con baja variabilidad mediante un filtro de varianza mínima. Las variables con varianza cercana a cero aportan escasa información discriminativa y pueden introducir ruido en el modelo. Su eliminación reduce dimensionalidad sin afectar significativamente la capacidad predictiva. Posteriormente se analizó la matriz de correlación de Pearson para identificar variables altamente correlacionadas. Cuanto dos características presentan una correlación superior a 0.9, se considera que aportan información redundante y se eliminan conservando aquellas que mantenían mayor independencia estadística.

Habiendo reducido el conjunto por criterios no supervisados, se aplicó una etapa de selección supervisada utilizando ANOVA. Este método evalúa la capacidad de cada característica para separar clases, comparando la variabilidad entre grupos frente a la variabilidad interna. La aplicación de ANOVA permitió ordenar las características según su poder discriminativo respecto a los cultivos. Este paso introduce información de las etiquetas en el proceso de selección, lo cual es fundamental cuando el objetivo es clasificación.

Finalmente, se aplicó un análisis de componentes principal, o PCA por sus siglas en inglés, reteniendo el número mínimo de componentes necesarios para explicar al menos 95% de la varianza total. Aunque PCA reduce la interpretabilidad directa de cada componente, mejora la compacidad del espacio y puede favorecer la generalización del modelo. Con esto se consolidó la ingeniería de características y brindó un espacio

mas eficiente desde el punto de vista computacional y estadístico.

Además del enfoque tabular, se trabajó una segunda línea basada en modelos de visión-lenguaje como lo es CLIP. En este caso, la ingeniería se enfocó menos en la transformación manual de características y más en estructuración adecuada de datos y regularización mediante *augmentations* o mejoras. Se generó una estructura organizada por clase, extrayendo recortes individuales de parcelas agrícolas. Esta reorganización permite entrenar modelos contrastivos donde cada imagen se asocia con una descripción textual de los cultivos presentes. En la primera versión se utilizó ViT-B/32, aplicando *fine-tuning* con una taza de aprendizaje baja para preservar representaciones visuales ya aprendidas.

En la segunda versión se incorporaron mejoras significativas como lo fueron *augmentations* geométricas y textuales y el uso de un *backbone* mas grande por medio de ViT-L/14 para incrementar la capacidad representacional. A su vez, se implementaron técnicas de regularización como *mixed precisión*, *gradient accumulation*, y *early stopping*, con el fin de controlar sobreajuste y optimizar uso de memoria.

En conjunto, el trabajo de análisis e ingeniería de características combina dos enfoques complementarios. Por un lado, un pipeline estadístico rigurosos que trasforma datos multitemporales en un espacio compacto y discriminativo. Por otro lado, una estrategia basada en aprendizaje profundo que aprovecha *embeddings* pre-entrenados y enriquecimiento semántico mediante *augmentations*.

IV. Implementación de modelos y resultados

Durante el desarrollo del proyecto se exploraron múltiples enfoques para la clasificación de cultivos a partir de imágenes satelitales del *dataset* PASTIS. Luego de haber preparado los datos se tomo en consideración los modelos a evaluar. Estos eran modelos de representación profunda basados en arquitectura visión-lenguaje, específicamente mediante *fine-tuning* de modelos como CLIP, implementación que se puede ver más a detalle en la imagen 4.

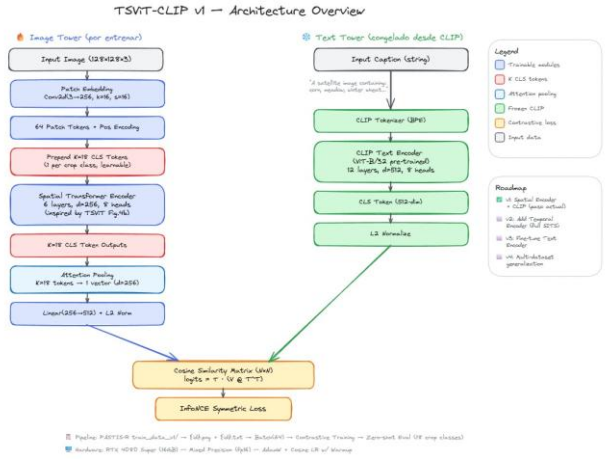

Imagen 4. *Blueprint* implementación CLIP

Cabe mencionar que aunque estos enfoques permitieron establecer una base inicial par el problema, se tomó una alternativa debido a las limitaciones que se encontraron con los datos satelitales multitemporales. Debido a que los cultivos presentan patrones fenológicos específicos a lo largo del ciclo agrícola, la evolución temporal de las señales espectrales constituye una fuerte información para su identificación. Por esta razón, se decidió implementar una arquitectura especializada en el modelado de secuencias satelitales, o *TSViT*, el cual a su vez se combinó con el algoritmo *BeMyEyes*.

El éxito de esta combinación viene a la facilidad de *TSViT* para procesar series temporales de imágenes multiespectrales mediante mecanismos de atención que capturan tanto la información temporal como espacial. En esta arquitectura, cada observación temporal se divide en parches espaciales que se convierten en *tokens* de entrada para el modelo. Mas adelante estos tokens son procesados mediante bloques de atención temporal que modelan la evolución de las características espectrales que integran la información entre las distintas regiones de la parcela.

Durante el entrenamiento se utilizó *Focal Loss* con *label smoothing* para la función de pérdida, con el objetivo de mitigar el impacto del desbalance entre clases presente en le *dataset*. Asimismo, se emplearon técnicas de optimización modernas como *mixed precisión*, acumulación de gradientes, y *early stopping*. Esto permitió entrenar el modelo de manera mas eficiente y reducir el riesgo de sobreajuste. Una vez entrenado el encoder visual, se integró un modulo adaptador que proyecta las representaciones generadas por *TSViT* hacia el espacio de embeddings en un modelo de lenguaje mediante una red MLP. Para ajustar esta integración se utilizó la técnica *LoRA*, o *Low-Rank Adaptation*, lo que permite adaptar el modelo multimodal sin modificar completamente sus parámetros.

El desempeño del modelo se evaluó utilizando el conjunto de prueba correspondiente al dataset, asegurando que no existiera fuga de información entre los conjuntos de entrenamiento, validación, y prueba. Durante esta etapa se cargaron los pesos correspondientes al mejor modelo obtenido durante el entrenamiento y se generaron predicciones sobre las muestras del conjunto de evaluación. Un ejemplo de los resultados se muestra a continuación en la imagen 5.

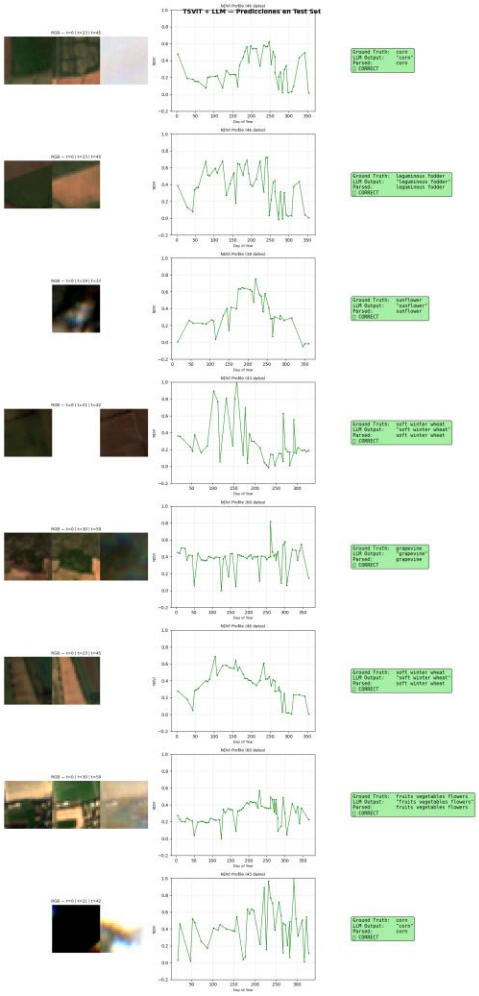

Imagen 5. Resultados.

Los resultados muestran que la arquitectura basada en *TSViT* con *BeMyEyes* logra captar de manera efectiva los patrones temporales presentes en las series de imágenes satelitales. Esto permite mejorar la capacidad de discriminación entre cultivos que pueden presentar características espaciales similares en una imagen individual, pero que exhiben comportamientos fenológicos distintos a lo largo del tiempo. En comparación los enfoques explorados previamente, particularmente aquellos basados en representaciones estadísticas o en modelos visión-lenguaje entrenados sobre imágenes individuales, el modelo *TSViT* demuestra una mejor adecuación al tipo de datos utilizado en este proyecto.

V. Conclusión

En este proyecto se exploró el uso de técnicas de visión computacional y modelos de inteligencia artificial para la identificación y compresión de cultivos a partir de imágenes satelitales. Utilizando el *dataset* PASTIS, se trabajó con información multiespectral y multitemporal proveniente de satélites *Sentinel*, lo cual permitió analizar las características espectrales de distintos cultivos a lo largo de su ciclo de crecimiento. El análisis inicial de los datos permitió comprender la estructura del *dataset*, así como identificar desafíos importantes como el desbalance entre clases.

Durante el desarrollo del proyecto se evaluaron distintos enfoques para abordar el problema de clasificación, inicialmente se aplicaron métodos de ingeniería de características que resumían las series temporales mediante estadísticas e índices espectrales como NDVI. Posteriormente se exploraron modelos de visión de lenguaje como CLIP. Sin embargo, debido a la naturaleza temporal de los datos satelitales se optó por implementar una arquitectura especializada, *TSViT*, la cual permite modelar simultáneamente la información espacial y la evolución temporal de las señales espectrales.

Los resultados obtenidos muestran que el uso de modelos diseñados específicamente para datos multitemporales permite capturar patrones fenológicos relevantes para la identificación de cultivos, en este sentido, la combinación de *TSViT* con componentes de interpretación basados en modelos de lenguaje representa un paso hacia el desarrollo de herramientas mas avanzadas para el análisis de información agrícola. Este trabajo demuestra el potencial de integrar visión computacional y modelos de lenguaje en aplicaciones de agricultura de precisión.

Referencias

[1] Huang, J. Y., Zhang, S., Liu, Q., Qin, G., Zhu, T., Naumann, T., Chen, M., & Poon, H. (2025, November 24). Be my eyes: Extending large language models to new modalities through multi-agent collaboration. arXiv.org. https://arxiv.org/abs/2511.19417

[2] Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., Krueger, G., & Sutskever, I. (2021, February 26). Learning transferable visual models from Natural Language Supervision. arXiv.org. https://arxiv.org/abs/2103.00020